基于Duo开发板的YOLOv5目标检测

1.配置docker开发环境

docker安装

在windows环境下，可以安装Docker Desktop for Windows，docker下载地址

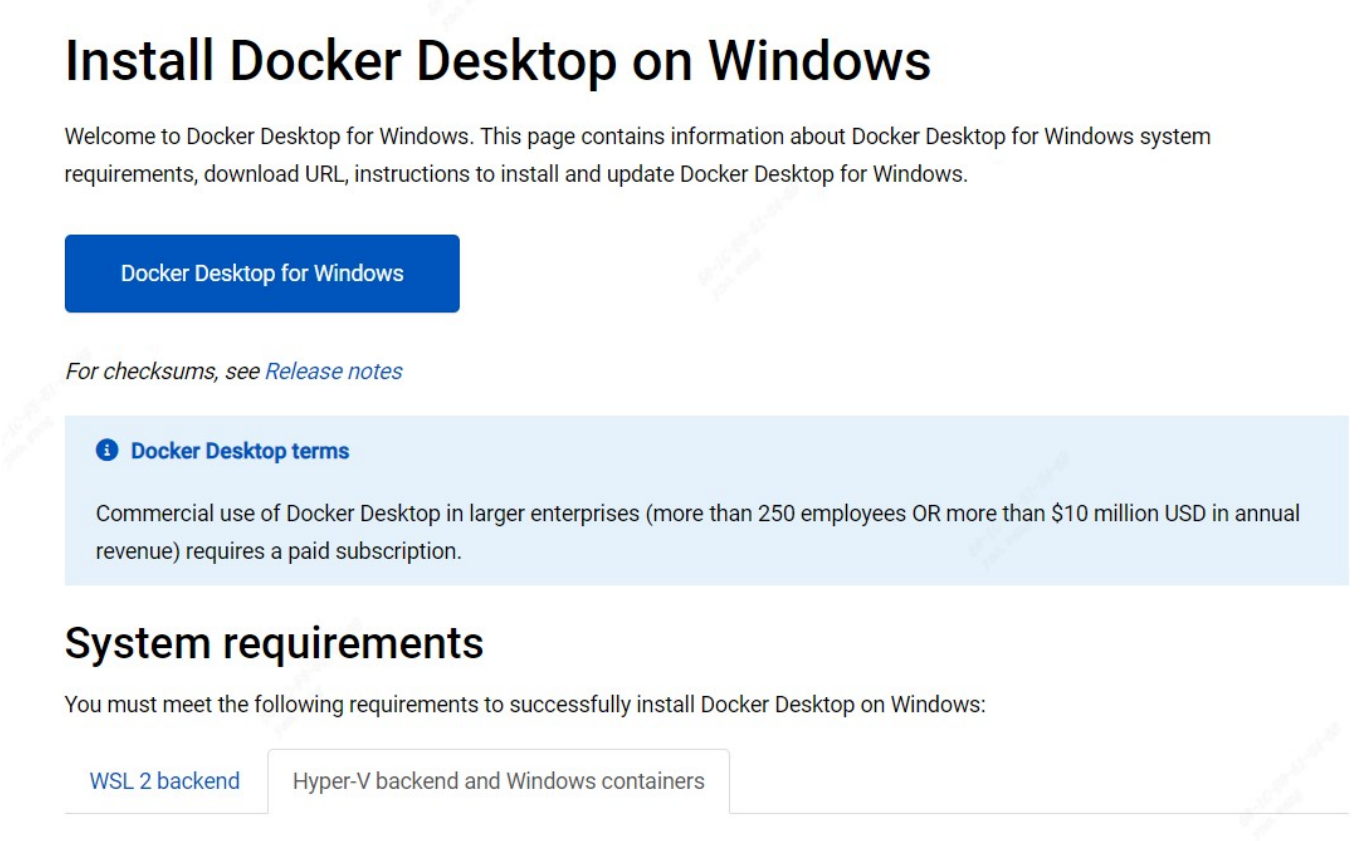

在Windows下运行docker需要相关依赖，即如图中所示，需要使用WSL2后端或者Hyper-V后端作为运行依赖

Hyper-V后端的启用方式如下：

1. 控制面板 —— 程序 —— 启用或关闭Windows功能

2. 找到Hyper-V，勾选Hyper-V管理工具和Hyper-V平台，等待系统文件配置完成后重启电脑

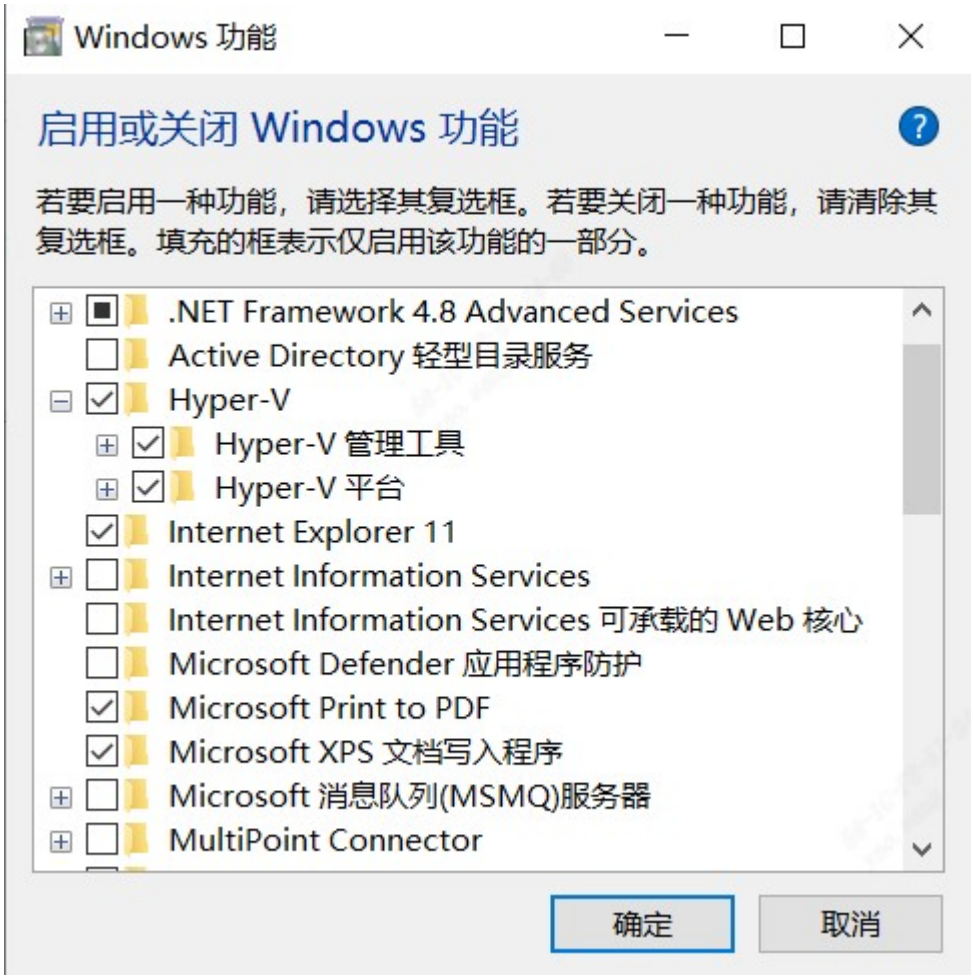

然后即可安装下载好Docker Desktop for Windows，在安装指引中根据选择的后端进行相应的勾选

安装完成后，需要重启电脑，然后即可使用docker

拉取开发所需docker镜像

从docker hub获取镜像文件：

```
docker pull sophgo/tpuc_dev:v2.2
```

启动容器

```
docker run --privileged --name <container_name> -v /workspace -it
sophgo/tpuc_dev:v2.2
```

其中，`<container_name>`为自己定义的容器名

获取开发工具包

可以从下载站台中获取开发工具包tpu-mlir_xxxx.tar.gz，xxxx为版本号，如tpu-mlir_v1.2.89-g77a2268f-20230703:

```
sftp://218.17.249.213
username: cvitek_mlir_2023
password: 7&2Wd%cu5k
```

另外，也可以从github上下载，下载地址

拷贝开发工具包

新建一个终端，并将开发工具包从windows拷贝到docker容器中

```
docker cp <path>/tpu-mlir_xxxx.tar.gz <container_name>:/tpu-
mlir_xxxx.tar.gz
```

其中，<path>为windows系统中开发工具包所在的文件目录，<container_name>为容器名

将工具包解压并添加环境变量

在docker容器中，解压工具包并添加环境变量

```
$ tar -zxvf tpu-mlir_xxxx.tar.gz
$ source ./tpu-mlir_xxxx/envsetup.sh
```

2.在windows下准备原始模型文件

准备yolov5开发工具包和yolov5n.pt文件

下载yolov5开发工具包以及yolov5n.pt文件， 下载完成后将工具包解压，并将yolov5n.pt文件放在yolov5-master/目录下

配置conda环境

新建Anaconda Prompt终端，新建conda虚拟环境并安装3.9.0版本的python，然后可使用如下指令安装1.12.1版本的pytorch，具体安装指令可根据需求选择，后续过程只需要用到CPU即可

```
# CUDA 10.2
conda install pytorch==1.12.1 torchvision==0.13.1 torchaudio==0.12.1
cudatoolkit=10.2 -c pytorch
# CUDA 11.3
```

```
conda install pytorch==1.12.1 torchvision==0.13.1 torchaudio==0.12.1
cudatoolkit=11.3 -c pytorch
# CUDA 11.6
conda install pytorch==1.12.1 torchvision==0.13.1 torchaudio==0.12.1
cudatoolkit=11.6 -c pytorch
# CPU Only
conda install pytorch==1.12.1 torchvision==0.13.1 torchaudio==0.12.1
cpuonly -c pytorch
```

然后将终端路径cd到开发工具包的yolov5-master/路径下，输入pip install -r requirements.txt安装其他依赖项

生成原始模型文件

在yolov5-master/目录下新建一个main.py文件，并在文件中写入如下代码：

```
import torch
from models.experimental import attempt_download
model = torch.load(attempt_download("./yolov5n.pt"),
map_location=torch.device('cpu'))['model'].float()
model.eval()
model.model[-1].export = True
torch.jit.trace(model, torch.rand(1, 3, 640, 640),
strict=False).save('./yolov5n_jit.pt')
```

然后找到/yolov5-master/models/yolo.py文件，将第63行到第79行的代码注释，并在第80行添加代码return x，如下图所示：

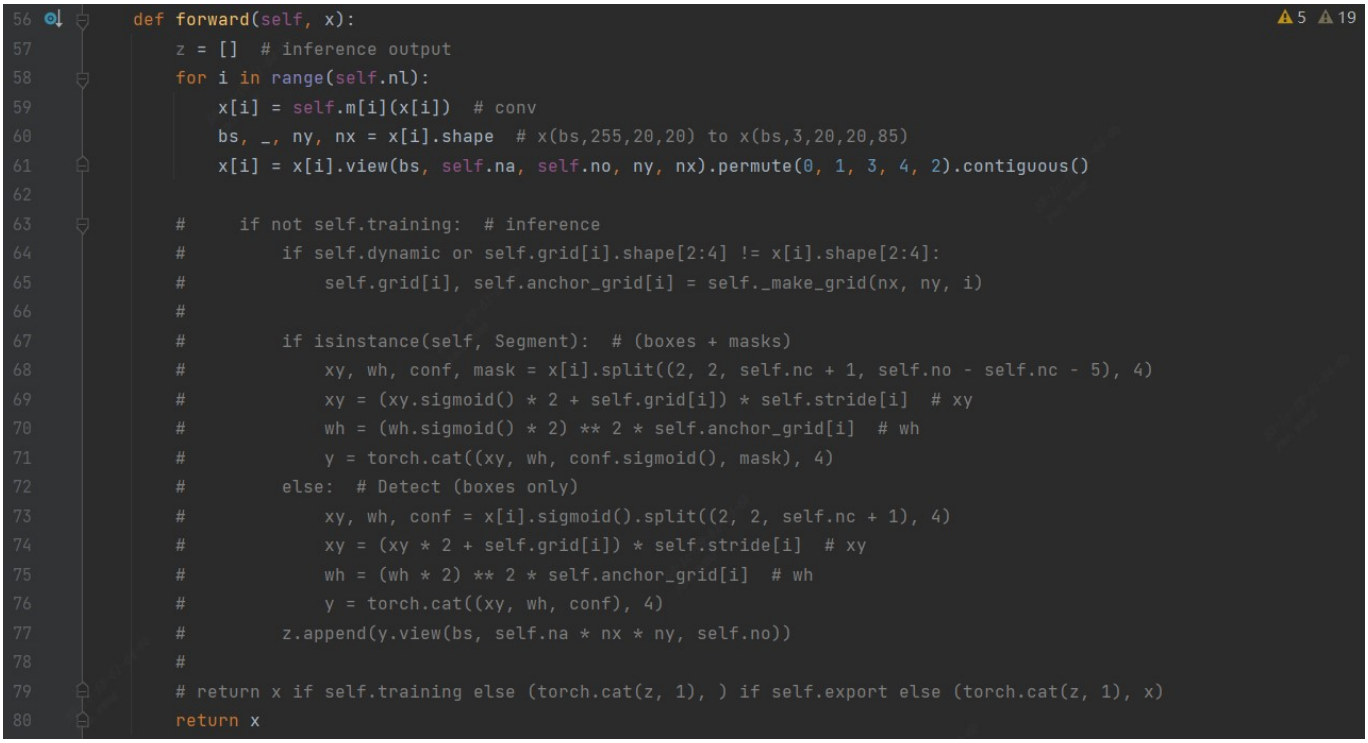

修改完成后，运行main.py文件，就会在yolov5-master目录下生成yolov5n_jit.pt文件，该文件即为所需的原始模型文件

3.在docker中准备工作目录

建立yolov5n_torch工作目录，注意是与tpu-mlir_xxxx同级的目录，并将模型文件和图片文件都放入该目录下

```
$ mkdir yolov5n_torch && cd yolov5n_torch
```

新建一个终端，将yolov5n_jit.pt从windows拷贝到docker中

```
docker cp <path>/yolov5-master/yolov5n_jit.pt
<container_name>:/workspace/yolov5n_torch/yolov5n_jit.pt
```

其中，<path>为windows系统中yolov5开发工具包所在的文件目录，<container_name>为容器名

再将图片文件放入yolov5n_torch/目录下并建立work目录

```
$ cp -rf $TPUC_ROOT/regression/dataset/COCO2017 .
$ cp -rf $TPUC_ROOT/regression/image .
$ mkdir work && cd work
```

这里的$TPUC_ROOT是环境变量，对应tpu-mlir_xxxx目录

4.TORCH转MLIR

本例中，模型是RGB输入，mean和scale分别为0,0,0和0.0039216,0.0039216,0.0039216
将torch模型转换为mlir模型的命令如下：

```
$ model_transform.py \
  --model_name yolov5n \
  --model_def ../yolov5n_jit.pt \
  --input_shapes [[1,3,640,640]] \
  --pixel_format "rgb" \
  --keep_aspect_ratio \
  --mean 0,0,0 \
  --scale 0.0039216,0.0039216,0.0039216 \
  --test_input ../image/dog.jpg \
  --test_result yolov5n_top_outputs.npz \
  --output_names 1219,1234,1249 \
  --mlir yolov5n.mlir
```

运行成功效果示例：

```
[1219                          ]      SIMILAR [PASSED]
    (1, 255, 80, 80) float32
    cosine_similarity      = 1.000000
    euclidean_similarity   = 1.000000
    sqnr_similarity        = 119.358044
[1234                          ]      SIMILAR [PASSED]
    (1, 255, 40, 40) float32
    cosine_similarity      = 1.000000
    euclidean_similarity   = 1.000000
    sqnr_similarity        = 118.279133
[1249                          ]      SIMILAR [PASSED]
    (1, 255, 20, 20) float32
    cosine_similarity      = 1.000000
    euclidean_similarity   = 1.000000
    sqnr_similarity        = 118.587103
200 compared
200 passed
  1 equal, 3 close, 196 similar
0 failed
  0 not equal, 0 not similar
min_similiarity = (0.9999998211860657, 0.9999981805550603, 114.30965423583984)
Target    yolov5n_top_outputs.npz
Reference yolov5n_ref_outputs.npz
npz compare PASSED.
compare 1249: 100%|                                                                                  | 200/200 [00:02<00:00, 76.38it/s]
[Success]: npz_tool.py compare yolov5n_top_outputs.npz yolov5n_ref_outputs.npz --tolerance 0.99,0.99 --except - -vv
```

转成mlir模型后，会生成一个`yolov5n.mlir`文件，该文件即为mlir模型文件，还会生成一个`yolov5n_in_f32.npz`文件，该文件是后续转模型的输入文件

```
root@fdb7a81ccdb3:/workspace/yolov5n_torch/work# ls
yolov5n.mlir         yolov5n_origin.mlir                    yolov5n_top_f32_all_weight.npz
yolov5n_in_f32.npz   yolov5n_top_f32_all_origin_weight.npz  yolov5n_top_outputs.npz
```

5.MLIR转INT8模型

生成校准表

在转int8模型之前需要先生成校准表，这里用现有的100张来自COCO2017的图片举例，执行calibration：

```
$ run_calibration.py yolov5n.mlir \
  --dataset ../COCO2017 \
  --input_num 100 \
  -o ./yolov5n_cali_table
```

运行完成后，会生成`yolov5n_cali_table`文件，该文件用于后续编译int8模型

```
root@fdb7a81ccdb3:/workspace/yolov5n_torch/work# ls
yolov5n.mlir         yolov5n_in_f32.npz   yolov5n_top_f32_all_origin_weight.npz  yolov5n_top_outputs.npz
yolov5n_cali_table   yolov5n_origin.mlir  yolov5n_top_f32_all_weight.npz
```

编译为int8模型

将mlir模型转换为int8模型的命令如下：

```
$ model_deploy.py \
  --mlir yolov5n.mlir \
```

```
    --quantize INT8 \
    --calibration_table ./yolov5n_cali_table \
    --chip cv180x \
    --test_input ../image/dog.jpg \
    --test_reference yolov5n_top_outputs.npz \
    --compare_all \
    --tolerance 0.96,0.72 \
    --fuse_preprocess \
    --debug \
    --model yolov5n_int8_fuse.cvimodel
```

编译成功效果示例：

```
[1219_f32                       ]       EQUAL [PASSED]
    (1, 255, 80, 80) float32
[1234_f32                       ]       EQUAL [PASSED]
    (1, 255, 40, 40) float32
[1249                           ]       EQUAL [PASSED]
    (1, 255, 20, 20) float32
[1249_f32                       ]       EQUAL [PASSED]
    (1, 255, 20, 20) float32
9 compared
9 passed
  9 equal, 0 close, 0 similar
0 failed
  0 not equal, 0 not similar
min_similiarity = (1.0, 1.0, inf)
Target    yolov5n_cv180x_int8_sym_model_outputs.npz
Reference yolov5n_cv180x_int8_sym_tpu_outputs.npz
npz compare PASSED.
compare 1249_f32: 100%|                                                  | 9/9 [00:00<00:00, 79.61it/s]
[Success]: npz_tool.py compare yolov5n_cv180x_int8_sym_model_outputs.npz yolov5n_cv180x_int8_sym_tpu_outputs.npz --toler
ance 0.99,0.90 --except - -vv
```

编译完成后，会生成`yolov5n_int8_fuse.cvimodel`文件

```
root@fdb7a81ccdb3:/workspace/yolov5n_torch/work# ls
_weight_map.csv                          yolov5n_int8_fuse.cvimodel
yolov5n.mlir                             yolov5n_origin.mlir
yolov5n_cali_table                       yolov5n_top_f32_all_origin_weight.npz
yolov5n_cv180x_int8_sym_final.mlir       yolov5n_top_f32_all_weight.npz
yolov5n_cv180x_int8_sym_model_outputs.npz yolov5n_top_outputs.npz
yolov5n_cv180x_int8_sym_tpu.mlir         yolov5n_tpu_addressed_cv180x_int8_sym_weight.npz
yolov5n_cv180x_int8_sym_tpu_outputs.npz  yolov5n_tpu_addressed_cv180x_int8_sym_weight_fix.npz
yolov5n_in_f32.npz                       yolov5n_tpu_lowered_cv180x_int8_sym_weight.npz
yolov5n_in_ori.npz
```

6.在Duo开发板上进行验证

连接Duo开发板

根据前面的教程完成duo开发板与电脑的连接，并使用mobaxterm开启终端操作Duo开发板

获取cvitek_tpu_sdk

可以从下载站台中获取开发工具包`cvitek_tpu_sdk_cv180x_musl_riscv64_rvv.tar.gz`，注意需要选择`cv180x`的工具包，下载站台如下：

```
sftp://218.17.249.213
username: cvitek_mlir_2023
password: 7&2Wd%cu5k
```

下载完成后，拷贝到docker中并在docker中进行解压

```
$ tar -zxvf cvitek_tpu_sdk_cv180x_musl_riscv64_rvv.tar.gz
```

解压完成后会生成`cvitek_tpu_sdk`文件夹

将开发工具包和模型文件拷贝到开发板上

在duo开发板的终端中，新建文件目录`/home/milkv/`

```
$ mkdir /home/milkv && cd /home/milkv
```

在docker的终端中，将开发工具包和模型文件拷贝到开发板上

```
$ scp -r cvitek_tpu_sdk root@192.168.42.1:/home/milkv
$ scp /workspace/yolov5n_torch/work/yolov5n_int8_fuse.cvimodel
root@192.168.42.1:/home/milkv/cvitek_tpu_sdk
```

设置环境变量

在duo开发板的终端中，进行环境变量的设置

```
$ cd ./cvitek_tpu_sdk
$ source ./envs_tpu_sdk.sh
```

进行目标检测

在duo开发板的终端中，输入如下命令进行目标检测

```
$ ./samples/samples_extra/bin/cvi_sample_detector_yolo_v5_fused_preprocess
\
  ./yolov5n_int8_fuse.cvimodel \
  ./samples/samples_extra/data/dog.jpg \
  yolov5n_out.jpg
```

检测成功结果示例:

```
CVI_NN_RegisterModel succeeded
get detection num: 3
obj 0: [222.069870 381.771240 173.271393 333.260345] score:0.733817 cls:dog
obj 1: [580.405090 123.967697 233.020157 89.783295] score:0.687424 cls:car
obj 2: [390.363068 287.245392 350.024567 305.919586] score:0.517759 cls:bicycle
------
3 objects are detected
------
CVI_NN_CleanupModel succeeded
```

运行成功后，会生成检测结果文件`yolov5n_out.jpg`

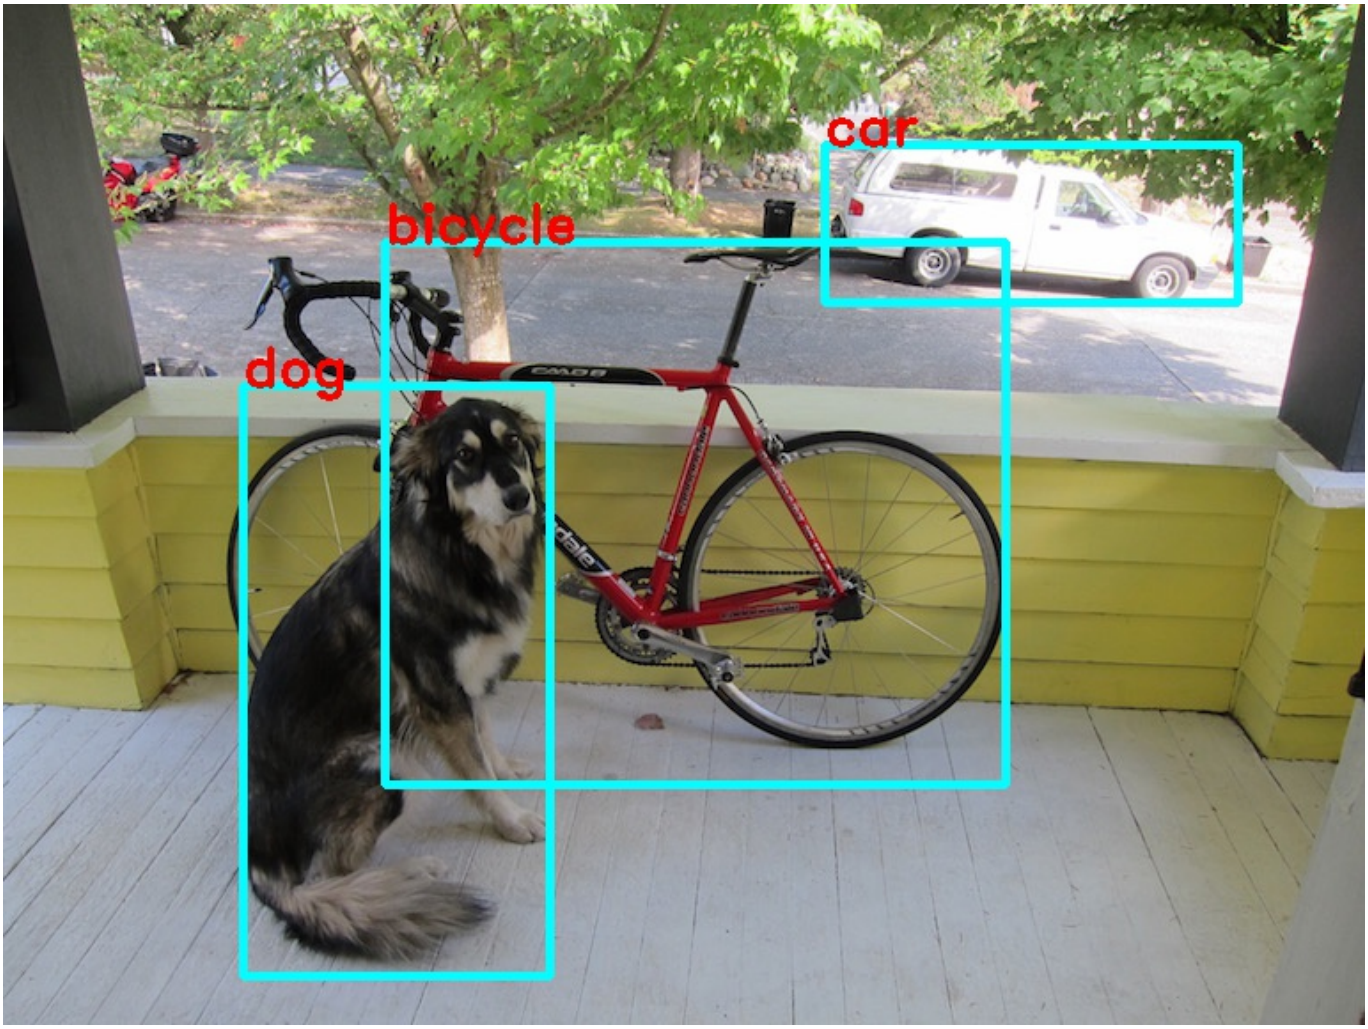

附录

正文涉及到的文件总结如下：

- TPU-MLIR模型转换工具链：tpu-mlir_v1.2.89-g77a2268f-20230703.tar.gz
- TPU SDK开发工具包：cvitek_tpu_sdk_cv180x_musl_riscv64_rvv.tar.gz
- （附）Sample测试例程源码：cvitek_tpu_samples.tar.gz
- （附）转换好的cvimodel包：cvimodel_samples_cv180x.tar.gz

正文提到的TPU开发所需的包文件可在下面sftp站点获取：

> sftp://218.17.249.213 user: cvitek_mlir_2023 password: 7&2Wd%cu5k

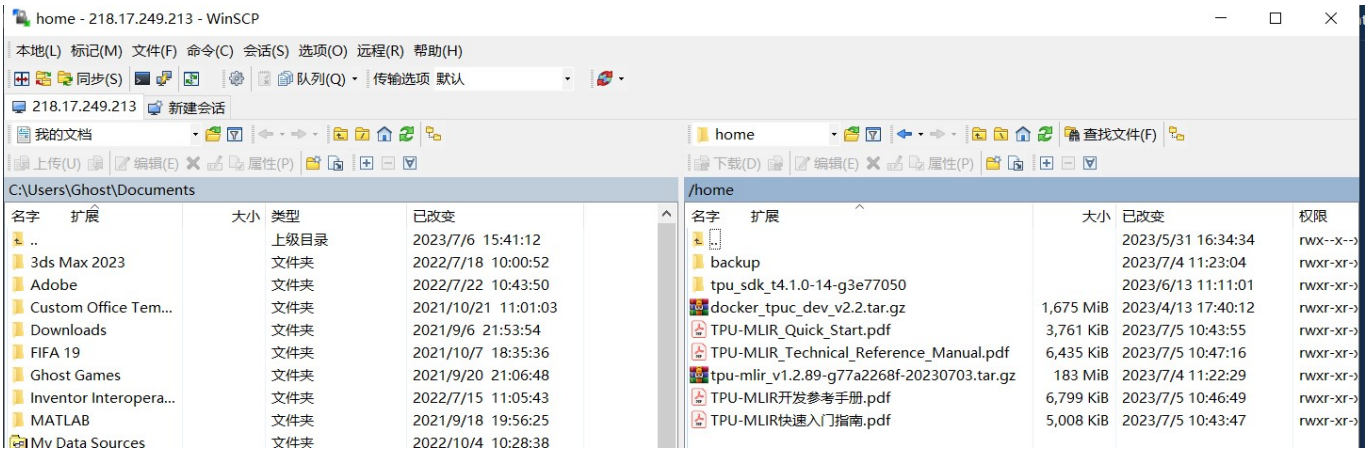

或者直接使用wget获取：

```
# TPU-MLIR模型转换工具链
wget --user='cvitek_mlir_2023' --password='7&2Wd%cu5k'
ftp://218.17.249.213/home/tpu-mlir_v1.2.89-g77a2268f-20230703.tar.gz

# TPU SDK开发工具包
wget --user='cvitek_mlir_2023' --password='7&2Wd%cu5k'
ftp://218.17.249.213/home/tpu_sdk_t4.1.0-14-
g3e77050/cvitek_tpu_sdk_cv180x_musl_riscv64_rvv.tar.gz

# （附）Sample测试例程源码
wget --user='cvitek_mlir_2023' --password='7&2Wd%cu5k'
ftp://218.17.249.213/home/tpu_sdk_t4.1.0-14-
g3e77050/cvitek_tpu_samples.tar.gz

# （附）转换好的cvimodel包
wget --user='cvitek_mlir_2023' --password='7&2Wd%cu5k'
ftp://218.17.249.213/home/tpu_sdk_t4.1.0-14-
g3e77050/cvimodel_samples_cv180x.tar.gz
```